handson_gpu_2022

October 31, 2022

1 Setup Iniziale

- 1. Attivare il supporto GPU in Runtime->Change Runtime Type->Hardware Accelerator
- 2. Check if pyCUDA è installato

```
[]: import pycuda

[]: !pip install pycuda

[2]: import pycuda

4. Controlla la versione di CUDA installata

[3]: !nvcc --version

nvcc: NVIDIA (R) Cuda compiler driver
Copyright (c) 2005-2021 NVIDIA Corporation
```

nvcc: NVIDIA (R) Cuda compiler driver Copyright (c) 2005-2021 NVIDIA Corporation Built on Sun_Feb_14_21:12:58_PST_2021 Cuda compilation tools, release 11.2, V11.2.152 Build cuda_11.2.r11.2/compiler.29618528_0

2 Esplorare la Bash

[5]: !ls
 drive handson_gpu_2022_files handson_gpu_2022.ipynb sample_data
[6]: mkdir test_dir
[7]: cd test_dir
 /content/test_dir
[]: ls
[11]: !touch ciao

```
[12]: ls
     ciao

[13]: rm ciao

[16]: ls

[17]: pwd

[17]: '/content/test_dir'

[18]: cd ..
     /content
[19]: !gcc --version
```

gcc (Ubuntu 7.5.0-3ubuntu1~18.04) 7.5.0 Copyright (C) 2017 Free Software Foundation, Inc. This is free software; see the source for copying conditions. There is NO warranty; not even for MERCHANTABILITY or FITNESS FOR A PARTICULAR PURPOSE.

3 Caratteristiche della GPU in uso

Proviamo a capire le caratteristiche della GPU che abbiamo a disposizione. E' importante sapere la struttura della GPU per capire che operazioni possiamo fare.

1							460.32.03		
1					•		Disp.A	•	
 		•			۱		Memory-Usage	1	MIG M
1							0:00:04.0 Off		(
١	N/A	40C	P8	9W /	70W	OM	iB / 15109MiB	I 0%	Default
Τ					I			1	N/A

```
ID
                                                                         Usage
        No running processes found
     oppure si può usare il modulo pycuda, interrogando le funzioni del driver
[21]: import pycuda.driver as drv
      drv.init()
      drv.get version()
      devn=drv.Device.count()
      print("N GPU "+str(devn))
      devices = \Pi
      for i in range(devn):
        devices.append(drv.Device(i))
      for sp in devices:
        print("GPU name: "+str(sp.name))
        print("Compute Capability = "+str(sp.compute_capability()))
        print("Total Memory = "+str(sp.total_memory()/(2.**20))+' MBytes')
        attr = sp.get_attributes()
        print(attr)
     N GPU 1
     GPU name: <bound method name of <pycuda._driver.Device object at
     0x7fcc247393b0>>
     Compute Capability = (7, 5)
     Total Memory = 15109.75 MBytes
     {pycuda._driver.device_attribute.ASYNC_ENGINE_COUNT: 3,
     pycuda. driver.device attribute.CAN MAP HOST MEMORY: 1,
     pycuda._driver.device_attribute.CAN_USE_HOST_POINTER_FOR_REGISTERED_MEM: 1,
     pycuda. driver.device attribute.CLOCK RATE: 1590000,
     pycuda._driver.device_attribute.COMPUTE_CAPABILITY_MAJOR: 7,
     pycuda. driver.device attribute.COMPUTE CAPABILITY MINOR: 5,
     pycuda._driver.device_attribute.COMPUTE_MODE:
     pycuda. driver.compute mode.DEFAULT,
     pycuda._driver.device_attribute.COMPUTE_PREEMPTION_SUPPORTED: 1,
     pycuda._driver.device_attribute.CONCURRENT_KERNELS: 1,
     pycuda._driver.device_attribute.CONCURRENT_MANAGED_ACCESS: 1,
     pycuda. driver.device attribute.DIRECT_MANAGED_MEM_ACCESS_FROM_HOST: 0,
     pycuda._driver.device_attribute.ECC_ENABLED: 1,
     pycuda._driver.device_attribute.GENERIC_COMPRESSION_SUPPORTED: 0,
     pycuda._driver.device_attribute.GLOBAL_L1_CACHE_SUPPORTED: 1,
     pycuda._driver.device_attribute.GLOBAL_MEMORY_BUS_WIDTH: 256,
     pycuda._driver.device_attribute.GPU_OVERLAP: 1,
     pycuda._driver.device_attribute.HANDLE_TYPE_POSIX_FILE_DESCRIPTOR_SUPPORTED: 1,
     pycuda. driver.device attribute.HANDLE TYPE WIN32 HANDLE SUPPORTED: 0,
     pycuda._driver.device_attribute.HANDLE_TYPE_WIN32_KMT_HANDLE_SUPPORTED: 0,
     pycuda._driver.device_attribute.HOST_NATIVE_ATOMIC_SUPPORTED: 0,
```

```
pycuda._driver.device_attribute.INTEGRATED: 0,
pycuda._driver.device_attribute.KERNEL_EXEC_TIMEOUT: 0,
pycuda._driver.device_attribute.L2_CACHE_SIZE: 4194304,
pycuda._driver.device_attribute.LOCAL_L1_CACHE_SUPPORTED: 1,
pycuda._driver.device_attribute.MANAGED_MEMORY: 1,
pycuda._driver.device_attribute.MAXIMUM_SURFACE1D_LAYERED_LAYERS: 2048,
pycuda._driver.device_attribute.MAXIMUM_SURFACE1D_LAYERED_WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_SURFACE1D_WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_SURFACE2D_HEIGHT: 65536,
pycuda._driver.device_attribute.MAXIMUM_SURFACE2D_LAYERED_HEIGHT: 32768,
pycuda._driver.device_attribute.MAXIMUM_SURFACE2D_LAYERED_LAYERS: 2048,
pycuda. driver.device attribute.MAXIMUM_SURFACE2D_LAYERED_WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_SURFACE2D_WIDTH: 131072,
pycuda._driver.device_attribute.MAXIMUM_SURFACE3D_DEPTH: 16384,
pycuda._driver.device_attribute.MAXIMUM_SURFACE3D_HEIGHT: 16384,
pycuda._driver.device_attribute.MAXIMUM_SURFACE3D_WIDTH: 16384,
pycuda._driver.device_attribute.MAXIMUM_SURFACECUBEMAP_LAYERED_LAYERS: 2046,
pycuda. driver.device attribute.MAXIMUM SURFACECUBEMAP LAYERED WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_SURFACECUBEMAP_WIDTH: 32768,
pycuda. driver.device attribute.MAXIMUM TEXTURE1D LAYERED LAYERS: 2048,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE1D_LAYERED_WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE1D_LINEAR_WIDTH: 268435456,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE1D_MIPMAPPED_WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE1D_WIDTH: 131072,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE2D_ARRAY_HEIGHT: 32768,
pycuda. driver.device attribute.MAXIMUM TEXTURE2D ARRAY NUMSLICES: 2048,
pycuda. driver.device attribute.MAXIMUM TEXTURE2D ARRAY WIDTH: 32768,
pycuda. driver.device attribute.MAXIMUM_TEXTURE2D_GATHER_HEIGHT: 32768,
pycuda. driver.device attribute.MAXIMUM_TEXTURE2D_GATHER_WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE2D_HEIGHT: 65536,
pycuda. driver.device attribute.MAXIMUM_TEXTURE2D_LINEAR_HEIGHT: 65000,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE2D_LINEAR_PITCH: 2097120,
pycuda. driver.device attribute.MAXIMUM_TEXTURE2D_LINEAR_WIDTH: 131072,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE2D_MIPMAPPED_HEIGHT: 32768,
pycuda. driver.device attribute.MAXIMUM TEXTURE2D MIPMAPPED WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE2D_WIDTH: 131072,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE3D_DEPTH: 16384,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE3D_DEPTH_ALTERNATE: 32768,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE3D_HEIGHT: 16384,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE3D_HEIGHT_ALTERNATE: 8192,
pycuda._driver.device_attribute.MAXIMUM_TEXTURE3D_WIDTH: 16384,
pycuda. driver.device attribute.MAXIMUM TEXTURE3D WIDTH ALTERNATE: 8192,
pycuda. driver.device attribute.MAXIMUM TEXTURECUBEMAP LAYERED LAYERS: 2046,
pycuda. driver.device attribute.MAXIMUM TEXTURECUBEMAP LAYERED WIDTH: 32768,
pycuda._driver.device_attribute.MAXIMUM_TEXTURECUBEMAP_WIDTH: 32768,
pycuda._driver.device_attribute.MAX_BLOCKS_PER_MULTIPROCESSOR: 16,
pycuda._driver.device_attribute.MAX_BLOCK_DIM_X: 1024,
pycuda._driver.device_attribute.MAX_BLOCK_DIM_Y: 1024,
```

```
pycuda._driver.device_attribute.MAX_BLOCK_DIM_Z: 64,
     pycuda._driver.device_attribute.MAX_GRID_DIM_X: 2147483647,
     pycuda._driver.device_attribute.MAX_GRID_DIM_Y: 65535,
     pycuda._driver.device_attribute.MAX_GRID_DIM_Z: 65535,
     pycuda. driver.device attribute.MAX PERSISTING L2 CACHE SIZE: 0,
     pycuda. driver.device attribute.MAX PITCH: 2147483647,
     pycuda. driver.device attribute.MAX REGISTERS PER BLOCK: 65536,
     pycuda._driver.device_attribute.MAX_REGISTERS_PER_MULTIPROCESSOR: 65536,
     pycuda._driver.device_attribute.MAX_SHARED_MEMORY_PER_BLOCK: 49152,
     pycuda._driver.device_attribute.MAX_SHARED_MEMORY_PER_BLOCK_OPTIN: 65536,
     pycuda. driver.device attribute.MAX_SHARED_MEMORY_PER_MULTIPROCESSOR: 65536,
     pycuda._driver.device_attribute.MAX_THREADS_PER_BLOCK: 1024,
     pycuda._driver.device_attribute.MAX_THREADS_PER_MULTIPROCESSOR: 1024,
     pycuda._driver.device_attribute.MEMORY_CLOCK_RATE: 5001000,
     pycuda._driver.device_attribute.MEMORY_POOLS_SUPPORTED: 1,
     pycuda._driver.device_attribute.MULTIPROCESSOR_COUNT: 40,
     pycuda._driver.device_attribute.MULTI_GPU_BOARD: 0,
     pycuda._driver.device_attribute.MULTI_GPU_BOARD_GROUP_ID: 0,
     pycuda._driver.device_attribute.PAGEABLE_MEMORY_ACCESS: 0,
     pycuda. driver.device attribute.PAGEABLE MEMORY ACCESS USES HOST PAGE TABLES: 0,
     pycuda._driver.device_attribute.PCI_BUS_ID: 0,
     pycuda. driver.device attribute.PCI DEVICE ID: 4,
     pycuda._driver.device_attribute.PCI_DOMAIN_ID: 0,
     pycuda._driver.device_attribute.READ_ONLY_HOST_REGISTER_SUPPORTED: 1,
     pycuda._driver.device_attribute.RESERVED_SHARED_MEMORY_PER_BLOCK: 0,
     pycuda. driver.device attribute.SINGLE TO DOUBLE PRECISION PERF_RATIO: 32,
     pycuda._driver.device_attribute.STREAM_PRIORITIES_SUPPORTED: 1,
     pycuda._driver.device_attribute.SURFACE_ALIGNMENT: 512,
     pycuda._driver.device_attribute.TCC_DRIVER: 0,
     pycuda._driver.device_attribute.TEXTURE_ALIGNMENT: 512,
     pycuda._driver.device_attribute.TEXTURE_PITCH_ALIGNMENT: 32,
     pycuda._driver.device_attribute.TOTAL_CONSTANT_MEMORY: 65536,
     pycuda._driver.device_attribute.UNIFIED_ADDRESSING: 1,
     pycuda._driver.device_attribute.WARP_SIZE: 32}
     oppure anche con il metodo DeviceData()
[22]: from pycuda import autoinit
      from pycuda.tools import DeviceData
      specs = DeviceData()
      print ('Max threads per block = '+str(specs.max_threads))
      print ('Warp size
                                   ='+str(specs.warp_size))
      print ('Warps per MP
                                   ='+str(specs.warps_per_mp))
      print ('Thread Blocks per MP = '+str(specs.thread_blocks_per_mp))
      print ('Registers
                                 ='+str(specs.registers))
      print ('Shared memory
                                 ='+str(specs.shared memory))
```

Max threads per block = 1024

```
Warp size =32
Warps per MP =64
Thread Blocks per MP =8
Registers =65536
Shared memory =49152
```

4 Esempio GPU in C

(comunque ci servirà dopo) Proviamo a scrivere e compulare un programma GPU in C. Notare il comando (magic) all'inizio che serve per salvare nel workspace il contenuto della cella in un file

```
[23]: %%writefile VecAdd.cu
      # include <stdio.h>
      # include <cuda runtime.h>
      // CUDA Kernel
      __global__ void vectorAdd(const float *A, const float *B, float *C, int_
      →numElements)
      {
          int i = blockDim.x * blockIdx.x + threadIdx.x;
          if (i < numElements)</pre>
          {
              C[i] = A[i] + B[i];
          }
      }
      /**
       * Host main routine
      int main(void)
      {
          int numElements = 15;
          size_t size = numElements * sizeof(float);
          printf("[Vector addition of %d elements]\n", numElements);
          float a[numElements],b[numElements],c[numElements];
          float *a_gpu,*b_gpu,*c_gpu;
          cudaMalloc((void **)&a_gpu, size);
          cudaMalloc((void **)&b_gpu, size);
          cudaMalloc((void **)&c_gpu, size);
          for (int i=0;i<numElements;++i ){</pre>
              a[i] = i*i;
              b[i] = i;
```

```
// Copy the host input vectors A and B in host memory to the device input
       →vectors in
          // device memory
          printf("Copy input data from the host memory to the CUDA device\n");
          cudaMemcpy(a_gpu, a, size, cudaMemcpyHostToDevice);
          cudaMemcpy(b_gpu, b, size, cudaMemcpyHostToDevice);
          // Launch the Vector Add CUDA Kernel
          int threadsPerBlock = 256;
          int blocksPerGrid =(numElements + threadsPerBlock - 1) / threadsPerBlock;
          printf("CUDA kernel launch with %d blocks of %d threads\n", blocksPerGrid, u
       →threadsPerBlock);
          vectorAdd<<<br/>blocksPerGrid, threadsPerBlock>>>(a_gpu, b_gpu, c_gpu,_
       →numElements);
          // Copy the device result vector in device memory to the host result vector
          // in host memory.
          printf("Copy output data from the CUDA device to the host memory\n");
          cudaMemcpy(c, c_gpu, size, cudaMemcpyDeviceToHost);
          for (int i=0;i<numElements;++i ){</pre>
              printf("%f \n",c[i]);
          }
          // Free device global memory
          cudaFree(a_gpu);
          cudaFree(b_gpu);
          cudaFree(c_gpu);
          printf("Done\n");
          return 0;
     Writing VecAdd.cu
[24]: ls
     drive/
                              handson_gpu_2022.ipynb
     test_dir/
     handson_gpu_2022_files/ sample_data/
     VecAdd.cu
[26]: !nvcc -o VecAdd VecAdd.cu -arch=compute_70 -code=sm_70
[27]: !./VecAdd
```

```
[Vector addition of 15 elements]
Copy input data from the host memory to the CUDA device
CUDA kernel launch with 1 blocks of 256 threads
Copy output data from the CUDA device to the host memory
0.000000
2.000000
6.000000
12.000000
20.000000
30.000000
42.00000
56.000000
72.000000
90.000000
110.000000
132,000000
156.000000
182.000000
210.000000
Done
```

5 Implementazione con pycuda

Facciamo un primo esempio con pycuda

importiamo i moduli ch eci servono

```
[28]: from pycuda import autoinit from pycuda import gpuarray import numpy as np
```

definiamo i vettori a, b e c sull'host. Tutti di lunghezza 15, a con i numeri da 0..14 e b con i quadrati. c è inizializzato a 0

```
[29]: aux = range(15)
a = np.array(aux).astype(np.float32)
b = (a*a).astype(np.float32)
c = np.zeros(len(aux)).astype(np.float32)
```

Definiamo i vettori sulla GPU e copiamo dentro il contenuto dei vettori a,b e c definiti sull'host

```
[30]: a_gpu = gpuarray.to_gpu(a)
b_gpu = gpuarray.to_gpu(b)
c_gpu = gpuarray.to_gpu(c)
```

un primo modo semplice per sommare i vettori e semplicemente usare il +

```
[31]: c_gpu=a_gpu+b_gpu
```

stampiamo i risultati

```
[32]: print(c_gpu)
```

```
[ 0. 2. 6. 12. 20. 30. 42. 56. 72. 90. 110. 132. 156. 182. 210.]
```

- [33]: c_gpu
- [33]: array([0., 2., 6., 12., 20., 30., 42., 56., 72., 90., 110., 132., 156., 182., 210.], dtype=float32)

Un secondo modo è quello di utilizzre il metodo elementwise, che applica la stessa "Operation" a tutti gli elementi dei vettori

- [35]: myCudaFunc(a_gpu,b_gpu,c_gpu)
- [36]: c_gpu
- [36]: array([0., 2., 6., 12., 20., 30., 42., 56., 72., 90., 110., 132., 156., 182., 210.], dtype=float32)

Il vantaggio è che si possono definire anche operazioni piu' complesse della semplice somma, ad esempio

in ogni caso l'operazione che vogliamo fare deve stare su una sola riga, quindi non può essere toppo complicata

```
[38]: lin_comb(3.,a_gpu,5.,b_gpu,c_gpu)
```

```
[39]: c_gpu
```

```
[39]: array([ 0., 8., 26., 54., 92., 140., 198., 266., 344., 432., 530., 638., 756., 884., 1022.], dtype=float32)
```

Il terzo metodo è il piu' "generico". SI utilizza il mtodo SourceModule che permette di definire anche kernel piu' complessi. L'idea è che questi kernel siano comunque scritti in Cuda/C

[40]: from pycuda.compiler import SourceModule

carichiamo il file contenente il codice in c che avevamo scritto prima (fare !ls se avete dubbi sul nome che gli avete dato)

```
[41]: !ls
```

drive handson_gpu_2022.ipynb test_dir VecAdd.cu handson_gpu_2022_files sample_data VecAdd

```
[42]: cudaCode = open("VecAdd.cu","r") #apro il file
myCUDACode = cudaCode.read() #copio il testo del file nella lista myCUDACode
```

dentro la lista myCUDACode ci sta il nostro programma:

```
[43]: myCUDACode
```

[43]: '# include <stdio.h>\n# include <cuda runtime.h>\n// CUDA Kernel\n global void vectorAdd(const float *A, const float *B, float *C, int numElements)\n{\n int i = blockDim.x * blockIdx.x + threadIdx.x;\n if (i < numElements)\n $C[i] = A[i] + B[i]; \ n$ \n n\n/**\n * Host main routine\n */\nint $main(void)\n{\n}$ int numElements = 15;\n size_t size = numElements * sizeof(float);\n printf("[Vector addition of %d elements]\\n", float a[numElements],b[numElements],c[numElements];\n numElements);\n \n float *a_gpu,*b_gpu,*c_gpu;\n \n cudaMalloc((void **)&a_gpu, size);\n cudaMalloc((void **)&b gpu, size);\n cudaMalloc((void **)&c gpu, size);\n \n for (int i=0;i<numElements;++i){\n \n</pre> $a[i] = i*i; \n$ $b[i] = i:\n$ // Copy the host input vectors A and B in host memory to the device printf("Copy input data from the input vectors in\n // device memory\n host memory to the CUDA device\\n");\n cudaMemcpy(a_gpu, a, size, cudaMemcpyHostToDevice);\n cudaMemcpy(b_gpu, b, size, // Launch the Vector Add CUDA Kernel\n cudaMemcpyHostToDevice);\n \n threadsPerBlock = 256;\n int blocksPerGrid =(numElements + threadsPerBlock -1) / threadsPerBlock;\n printf("CUDA kernel launch with %d blocks of %d threads\\n", blocksPerGrid, threadsPerBlock);\n vectorAdd<<<blooksPerGrid, threadsPerBlock>>>(a_gpu, b_gpu, c_gpu, numElements);\n \n // Copy the device result vector in device memory to the host result vector\n // in host memory.\n printf("Copy output data from the CUDA device to the host memory\\n");\n cudaMemcpy(c, c_gpu, size, cudaMemcpyDeviceToHost);\n \n for (int i=0;i<numElements;++i){\n</pre> printf("%f \\n",c[i]);\n // Free device global memory\n cudaFree(a gpu);\n cudaFree(b gpu);\n printf("Done\\n");\n cudaFree(c_gpu);\n \n return 0;\n}\n'

compiliamo il codice just-in-time con il metodo SourceModule()

SourceModule() chiama il coompilatore e genera dentro myCode una funzione per avere a disposizione il kernel.

```
[44]: myCode = SourceModule(myCUDACode)
```

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: UserWarning: The CUDA compiler succeeded, but said the following: kernel.cu(17): warning: function "main" cannot be declared in a linkage-specification

"""Entry point for launching an IPython kernel.

ora il kernel (e l'host) è compilato. Importiamolo nel programma in python

```
[45]: importedKernel = myCode.get_function("vectorAdd")
```

Fino ad ora la "geometria" della GPU l'ha gestita automaticamente pyCuda. Ora siamo noi a definire la "geometria" della GPU che vogliamo usare:

```
[46]: nThreadsPerBlock = 256
nBlockPerGrid = 1
nGridsPerBlock = 1
```

resettiamo il vettore c_gpu (per essere sicuri sia vuoto)

```
[47]: c_gpu.set(c) c_gpu
```

Il puntatore nella memoria gpu è dato dall'attributo gpudata

```
[48]: a_gpu.gpudata
```

[48]: <pycuda._driver.DeviceAllocation at 0x7fcc161cc080>

```
[49]: b_gpu.gpudata
```

[49]: <pycuda._driver.DeviceAllocation at 0x7fcc161cc2b0>

lanciamo il kernel importato passandogli i **puntatori** dei vettori e la geometria della GPU

```
[50]: importedKernel(a_gpu.gpudata, b_gpu.gpudata, c_gpu.gpudata, u_block=(nThreadsPerBlock,nBlockPerGrid,nGridsPerBlock))
```

[51]: c_gpu


```
[51]: array([ 0., 2., 6., 12., 20., 30., 42., 56., 72., 90., 110., 132., 156., 182., 210.], dtype=float32)
```

ovviamente questo ultimo metodo è eccessivo se ho

6 Somma di Matrici


Puliamo la memoria

```
[52]: %reset
     Once deleted, variables cannot be recovered. Proceed (y/[n])? y
     importiamo le cose che ci servono
[53]: import numpy as np
      from pycuda import gpuarray, autoinit
      import pycuda.driver as cuda
      from pycuda.tools import DeviceData
      from pycuda.tools import OccupancyRecord as occupancy
     inizializziamo gli array con le dimensioni appropriate
[54]: presCPU, presGPU = np.float32, 'float'
      #presCPU, presGPU = np.float64, 'double'
      a_cpu = np.random.random((512,512)).astype(presCPU)
      b_cpu = np.random.random((512,512)).astype(presCPU)
      c_cpu = np.zeros((512,512), dtype=presCPU)
     carichiamo matplotlib per poterlo usare nella Ipython
[55]: %matplotlib inline
[56]: from matplotlib import pyplot as plt
[57]: plt.imshow(a_cpu)
      plt.colorbar()
[57]: <matplotlib.colorbar.Colorbar at 0x7fcc160380d0>
```



[58]: plt.imshow(b_cpu) plt.colorbar()

[58]: <matplotlib.colorbar.Colorbar at 0x7fcc100b6750>



copiamo gli array sulla gpu

```
[59]: a_gpu = gpuarray.to_gpu(a_cpu)
      b_gpu = gpuarray.to_gpu(b_cpu)
      c_gpu = gpuarray.to_gpu(c_cpu)
[60]: c_gpu
[60]: array([[0., 0., 0., ..., 0., 0., 0.],
             [0., 0., 0., ..., 0., 0., 0.],
             [0., 0., 0., ..., 0., 0., 0.]
             [0., 0., 0., ..., 0., 0., 0.]
             [0., 0., 0., ..., 0., 0., 0.]
             [0., 0., 0., ..., 0., 0., 0.]], dtype=float32)
     facciamo la somma prima sull'host
[61]: c_cpu=a_cpu+b_cpu
[62]: c_cpu
[62]: array([[1.2318479 , 0.7115891 , 1.0627784 , ..., 1.0367434 , 1.2572979 ,
              1.435501 ],
             [1.1625738 , 0.69545865, 1.1233734 , ..., 1.7289808 , 0.98316765,
              1.472131 ],
             [0.31298584, 0.7491113, 0.5359408, ..., 0.9131348, 0.6572113,
              0.75546235],
             [1.0218427 , 1.3309641 , 0.73231196, ..., 1.7113471 , 1.4630361 ,
              0.8734757],
             [1.1179438 , 1.7768974 , 1.6918807 , ..., 1.1337817 , 0.73312706,
              0.67441964],
             [0.6375501, 0.8411865, 0.85855544, ..., 0.9857786, 0.13109833,
              0.6627484 ]], dtype=float32)
     misuriamo il tempo che ci vuole sull'host per fare la somma
[63]: t_cpu = %timeit -o c_cpu = a_cpu+b_cpu
     172 \mu s \pm 9.2 \mu s per loop (mean \pm std. dev. of 7 runs, 10000 loops each)
     definiamo il kernel gpu per fare la somma
[64]: cudaKernel = '''
      __global__ void matrixAdd(float *A, float *B, float *C)
          int tid_x = blockDim.x * blockIdx.x + threadIdx.x;
          int tid_y = blockDim.y * blockIdx.y + threadIdx.y;
```

```
int tid = gridDim.x * blockDim.x * tid_y + tid_x;
C[tid] = A[tid] + B[tid];
}
'''
```

ora dobbiamo compilare questo kernel e generare la funzione da usare in python

```
[65]: from pycuda.compiler import SourceModule
myCode = SourceModule(cudaKernel)
```

```
[66]: addMatrix = myCode.get_function("matrixAdd") # The output of get_function is_\sqcup \hookrightarrow the GPU-compiled function.
```

```
[67]: type(addMatrix)
```

[67]: pycuda._driver.Function

dobbiamo decidere la geoemtria della GPU. Ad esempio si possono cercare di sfruttare tutti i threads a disposizione in un blocco. Quati thread ci sono in un blocco?

```
[68]: dev = cuda.Device(0)
  devdata = DeviceData(dev)
  print ("Using device : "+dev.name() )
  print("Max threads per block: "+str(dev.max_threads_per_multiprocessor))
```

Using device : Tesla T4
Max threads per block: 1024

Quindi possiamo usare blocchi 32x32. Le nostre matrici sono 512x512, per cui dobbiamo usare 16x16 blocchi

```
[69]: cuBlock = (32,32,1)
cuGrid = (16,16,1)
```

abbiamo già compilato il kernel con SourceModule. Ora abbiamo due modi per lanciarlo. O chiamiamo direttamente la funzione (come abbiamo fatto sopra per la somam di vettori)

```
kernelFunction(arg1,arg2, ...,block=(n,m,l),grid=(r,s,t)
```

oppure usiamo la "preparation"

kernelFunction.prepare('ABC..') # Each letter corresponds to an input data type of the function kernelFunction.prepared_call(grid,block,arg1.gpudata,arg2,...) # When using GPU arrays, they so

il primo metodo è, per noi

```
[70]: addMatrix(a_gpu,b_gpu,c_gpu,block=cuBlock,grid=cuGrid)
```


con la preparation è possibile midurare il tempo di esecuzione

```
[71]: addMatrix.prepare('PPP')
      addMatrix.prepared_call(cuGrid,cuBlock,a_gpu.gpudata,b_gpu.gpudata,c_gpu.
       →gpudata)
[72]: time2 = addMatrix.prepared_timed_call(cuGrid,cuBlock,a_gpu.gpudata,b_gpu.
       ⇒gpudata,c_gpu.gpudata)
[73]: time2()
[73]: 2.7008000761270522e-05
     per controllare il risultato dobbiamo copiare il risultato dalla gpu alla cpu
[74]: c = c_gpu.get()
     controlliamo il risultato per cpu e gpu
[75]: c, c_cpu
[75]: (array([[1.2318479 , 0.7115891 , 1.0627784 , ..., 1.0367434 , 1.2572979 ,
               1.435501 ],
              [1.1625738, 0.69545865, 1.1233734, ..., 1.7289808, 0.98316765,
               1.472131 ],
              [0.31298584, 0.7491113 , 0.5359408 , ..., 0.9131348 , 0.6572113 ,
               0.75546235],
              [1.0218427 , 1.3309641 , 0.73231196, ..., 1.7113471 , 1.4630361 ,
               0.8734757],
              [1.1179438 , 1.7768974 , 1.6918807 , ..., 1.1337817 , 0.73312706,
               0.67441964],
              [0.6375501, 0.8411865, 0.85855544, ..., 0.9857786, 0.13109833,
               0.6627484 ]], dtype=float32),
       array([[1.2318479 , 0.7115891 , 1.0627784 , ..., 1.0367434 , 1.2572979 ,
               1.435501 ],
              [1.1625738 , 0.69545865 , 1.1233734 , ..., 1.7289808 , 0.98316765 ,
               1.472131 ],
              [0.31298584, 0.7491113 , 0.5359408 , ..., 0.9131348 , 0.6572113 ,
               0.75546235],
              [1.0218427 , 1.3309641 , 0.73231196 , ..., 1.7113471 , 1.4630361 ,
               0.8734757],
              [1.1179438 , 1.7768974 , 1.6918807 , ..., 1.1337817 , 0.73312706,
               0.67441964],
              [0.6375501, 0.8411865, 0.85855544, ..., 0.9857786, 0.13109833,
               0.6627484 ]], dtype=float32))
```

per confrontare meglio, guardiamo i plot

```
[76]: plt.imshow(c-c_cpu,interpolation='none')
plt.colorbar()
```

[76]: <matplotlib.colorbar.Colorbar at 0x7fcbfbfc38d0>



```
[77]: np.sum(np.sum(np.abs(c_cpu-c)))
```

[77]: 0.0

in effetti i risultati sono uguali

7 Moltiplicazione tra matrici

scriviamo un kernel per la moltiplicazione di matrici

```
[78]: cudaKernel2 = '''
__global__ void matrixMul(float *A, float *B, float *C)
{
    int tid_x = blockDim.x * blockIdx.x + threadIdx.x; // Row
    int tid_y = blockDim.y * blockIdx.y + threadIdx.y; // Column
    int matrixDim = gridDim.x * blockDim.x;
    int tid = matrixDim * tid_y + tid_x; // element i,j

float aux=0.0f;
```

compiliamo e importiamo con SourceModule

```
[79]: myCode = SourceModule(cudaKernel2)
mulMatrix = myCode.get_function("matrixMul")
```

eseguiamolo con la stessa struttura a blocchi definite per la somma di matrici

```
[80]: mulMatrix(a_gpu,b_gpu,c_gpu,block=cuBlock,grid=cuGrid)
```

sulla CPU sarà invece

```
[81]: dotAB = np.dot(a_cpu, b_cpu)
```

vediamo il risultato è lo stesso

```
[82]: diff = np.abs(c_gpu.get()-dotAB)
np.sum(diff)
```

[82]: 8.635231

```
[83]: plt.imshow(diff,interpolation='none') plt.colorbar()
```

[83]: <matplotlib.colorbar.Colorbar at 0x7fcbf970cb90>


```
0
                                                      0.000175
100
                                                      0.000150
                                                      0.000125
200
                                                      0.000100
300
                                                     - 0.000075
                                                     - 0.000050
400
                                                      0.000025
500
                                                     - 0.000000
           100
                    200
                            300
                                    400
                                             500
```

```
[84]: dotAB
[84]: array([[121.42797 , 122.31373 , 120.10916 , ..., 119.41626 , 121.96463 ,
              118.80441 ],
             [130.3919 , 129.17444 , 126.29321 , ..., 130.36664 , 131.5235 ,
              128.30759],
             [124.68309 , 122.24606 , 120.65952 , ..., 119.66283 , 123.355774,
              121.70793 ],
             [126.59974 , 126.97113 , 126.88341 , ..., 124.75375 , 123.9772 ,
              127.03604],
             [129.1057 , 128.1775 , 128.33745 , ..., 125.19934 , 126.26902 ,
              126.57745 ],
             [124.317215, 119.97131 , 122.27707 , ..., 120.317505, 123.454956,
              122.56614 ]], dtype=float32)
[85]: c_gpu
[85]: array([[121.42807 , 122.31372 , 120.109215, ..., 119.41626 , 121.9646 ,
              118.80444 ],
             [130.39189 , 129.17444 , 126.2932 , ..., 130.36668 , 131.52351 ,
              128.30759],
             [124.68307, 122.24605, 120.659485, ..., 119.662834, 123.35574,
              121.707886],
             ...,
```

```
[126.59972 , 126.97111 , 126.88342 , ..., 124.753716, 123.9772 ,
              127.035995],
             [129.10559 , 128.17752 , 128.33742 , ..., 125.19935 , 126.26911 ,
              126.57746],
             [124.317154, 119.971306, 122.2771 , ..., 120.317474, 123.45495 ,
              122.56615 ]], dtype=float32)
[86]: presCPU, presGPU = np.float64, 'double'
      a_cpu = np.random.random((512,512)).astype(presCPU)
      b_cpu = np.random.random((512,512)).astype(presCPU)
      c_cpu = np.zeros((512,512), dtype=presCPU)
[87]: a_gpu = gpuarray.to_gpu(a_cpu)
      b_gpu = gpuarray.to_gpu(b_cpu)
      c_gpu = gpuarray.to_gpu(c_cpu)
[88]: a cpu.dtype
[88]: dtype('float64')
[89]: cudaKernel3 = '''
      __global__ void matrixMul64(double *A, double *B, double *C)
          int tid x = blockDim.x * blockIdx.x + threadIdx.x; // Row
          int tid_y = blockDim.y * blockIdx.y + threadIdx.y; // Column
          int matrixDim = gridDim.x * blockDim.x;
          int tid = matrixDim * tid_y + tid_x; // element i,j
          double aux = 0.0;
          for ( int i=0 ; i<matrixDim ; i++ ){</pre>
              //
              aux += A[matrixDim * tid_y + i]*B[matrixDim * i + tid_x] ;
          }
          C[tid] = aux;
      1.1.1
[90]: myCode64 = SourceModule(cudaKernel3)
      mulMatrix64 = myCode64.get_function("matrixMul64")
[91]: mulMatrix64(a_gpu,b_gpu,c_gpu,block=cuBlock,grid=cuGrid)
[92]: dotAB = np.dot(a_cpu, b_cpu)
```

```
[93]: c_gpu.dtype
[93]: dtype('float64')
[94]: dotAB.dtype
[94]: dtype('float64')
[95]: diff = np.abs(c_gpu.get()-dotAB)
[96]: plt.imshow(diff,interpolation='none')
    plt.colorbar()
```

[96]: <matplotlib.colorbar.Colorbar at 0x7fcbf966b510>



[96]:

8 Ancora sulla somma di vettori

[97]: %reset

Once deleted, variables cannot be recovered. Proceed (y/[n])? y $% \left(\frac{1}{2}\right) =\frac{1}{2}\left(\frac{1}{2}\right) +\frac{1}{2}\left(\frac$


Vogliamo confrontare i tempi per la somma di vettori di dimensione variabile, tra CPU e GPU

Iniziamo con la versione CPU

```
[98]: %matplotlib inline
       from matplotlib import pyplot as plt
 [99]: import numpy as np
[100]: from time import time
       def myColorRand():
           return (np.random.random(),np.random.random(),np.random.random())
[101]: dimension = [2**i for i in range(5,25)]
       myPrec = np.float32
[102]: dimension
[102]: [32,
        64,
        128,
        256,
        512,
        1024,
        2048,
        4096,
        8192,
        16384,
        32768,
        65536,
        131072,
        262144,
        524288,
        1048576,
        2097152,
        4194304,
        8388608,
        167772167
[103]: nLoops = 100
       timeCPU = []
       for n in dimension:
           v1_cpu = np.random.random(n).astype(myPrec)
           v2_cpu = np.random.random(n).astype(myPrec)
           tMean = 0
           for i in range(nLoops):
               t = time()
               v = v1_cpu+v2_cpu
               t = time() - t
               tMean += t/nLoops
```

timeCPU.append(tMean)

```
[104]: plt.figure(1,figsize=(10,6))
  plt.semilogx(dimension,timeCPU,'b-*')
  plt.ylabel('Time (sec)')
  plt.xlabel('N')
  plt.xticks(dimension, dimension, rotation='vertical')
  plt.show()
```




Proviamo a fare la versione GPU


Per prima cosa guardiamo la semplice somma (primo metodo)

```
[105]: import pycuda
from pycuda import gpuarray

[106]: timeGPU1 = []
bandWidth1 = []
for n in dimension:
    v1_cpu = np.random.random(n).astype(myPrec)
    v2_cpu = np.random.random(n).astype(myPrec)
    t1Mean = 0
    t2Mean = 0
    for i in range(nLoops):
```


```
t = time()
    vaux = gpuarray.to_gpu(v1_cpu)
    t = time() -t
    t1Mean += t/nLoops
bandWidth1.append(t1Mean)
v1_gpu = gpuarray.to_gpu(v1_cpu)
v2_gpu = gpuarray.to_gpu(v2_cpu)
for i in range(nLoops):
    t = time()
    v = v1_gpu+v2_gpu
    t = time() -t
    t2Mean += t/nLoops
timeGPU1.append(t2Mean)
v1_gpu.gpudata.free()
v2_gpu.gpudata.free()
v.gpudata.free()
```





proviamo anche a valutare il tempo di trasferimento su GPU


```
[109]: plt.figure(1,figsize=(10,6))
    sizeMB = np.array(dimension)/(2.**20)
    plt.semilogx(sizeMB,bandWidth1,'m-+',label='GPU copy HostToDevice')
    plt.semilogx(sizeMB,timeGPU1,'r-*',label='GPU Simple Sum')
    plt.ylabel('Time (sec)')
```



proviamo ad usare elementwise (secondo metodo)

```
v1_gpu = gpuarray.to_gpu(v1_cpu)
v2_gpu = gpuarray.to_gpu(v2_cpu)
vr_gpu = gpuarray.to_gpu(v2_cpu)
t3Mean=0
for i in range(nLoops):
    start.record()
    myCudaFunc(v1_gpu,v2_gpu,vr_gpu)
    end.record()
    end.synchronize()
    secs = start.time_till(end)*1e-3
    t3Mean+=secs/nLoops
timeGPU2.append(t3Mean)
v1_gpu.gpudata.free()
v2_gpu.gpudata.free()
vr_gpu.gpudata.free()
```

[113]: <matplotlib.legend.Legend at 0x7fcbf8fd4d90>



Implementazione con SourceModule. E' possibile variare la geometria di griglia e blocchi

```
[114]: from pycuda.compiler import SourceModule
[115]: presCPU, presGPU = np.float32, 'float'
      cudaCode = open("VecAdd.cu","r")
      cudaCode = cudaCode.read()
      cudaCode = cudaCode.replace('float',presGPU )
      myCode = SourceModule(cudaCode)
      vectorAddKernel = myCode.get_function("vectorAdd")
      vectorAddKernel.prepare('PPP')
[115]: <pycuda._driver.Function at 0x7fcc1618db20>
 []: timeGPU3 = []
      occupancyMesure=[]
      for nt in [32,64,128,256,512,1024]:
           aux = \Pi
          aux0cc = []
          for n in dimension:
              v1_cpu = np.random.random(n).astype(myPrec)
              v2_cpu = np.random.random(n).astype(myPrec)
              v1_gpu = gpuarray.to_gpu(v1_cpu)
              v2_gpu = gpuarray.to_gpu(v2_cpu)
              vr_gpu = gpuarray.to_gpu(v2_cpu)
              cudaBlock = (nt, 1, 1)
              cudaGrid = (int((n+nt-1)/nt),1,1)
              cudaCode = open("VecAdd.cu","r")
               cudaCode = cudaCode.read()
               cudaCode = cudaCode.replace('float',presGPU )
               downVar = ['blockDim.x','blockDim.y','blockDim.z','gridDim.x','gridDim.
        upVar
                         = [str(cudaBlock[0]),str(cudaBlock[1]),str(cudaBlock[2]),
                            str(cudaGrid[0]),str(cudaGrid[1]),str(cudaGrid[2])]
               dicVarOptim = dict(zip(downVar,upVar))
              for i in downVar:
                   cudaCode = cudaCode.replace(i,dicVarOptim[i])
               #print cudaCode
              myCode = SourceModule(cudaCode)
              vectorAddKernel = myCode.get_function("vectorAdd")
              vectorAddKernel.prepare('PPP')
              print ('Size= '+str(n)+" threadsPerBlock= "+str(nt))
```

print (str(cudaBlock)+" "+str(cudaGrid))


```
t5Mean = 0
               for i in range(nLoops):
                   timeAux = vectorAddKernel.
        →prepared_timed_call(cudaGrid,cudaBlock,v1_gpu.gpudata,v2_gpu.gpudata,vr_gpu.
        →gpudata)
                   t5Mean += timeAux()/nLoops
               aux.append(t5Mean)
               v1_gpu.gpudata.free()
               v2_gpu.gpudata.free()
               vr_gpu.gpudata.free()
           timeGPU3.append(aux)
           occupancyMesure.append(auxOcc)
[117]: timeGPU3[0]
[117]: [7.949759974144397e-06,
        7.21632000524551e-06,
        7.254079999402168e-06,
        7.3756800033152106e-06,
        7.390080024488268e-06,
        7.483840039931238e-06,
        7.038079998455943e-06,
        8.753280001692472e-06,
        8.093119999393824e-06,
        8.041280033066873e-06,
        9.224319923669098e-06,
        1.487168000079691e-05,
        1.6904639974236497e-05,
        2.615999998524785e-05,
        5.546847987920043e-05,
        0.00010585823982954026,
        0.00020728544026613226,
        0.00041910720199346525,
        0.0008457052761316303,
        0.0014863404846191404]
[118]: plt.figure(1,figsize=(10,6),dpi=100)
       plt.semilogx(dimension,timeGPU1,'y-*',label='GPU Simple Sum')
       plt.semilogx(dimension,timeGPU2,'g-*',label='GPU ElementWise Sum')
       count = 0
       for nt in [32,64,128,256,512,1024]:
           plt.semilogx(dimension,timeGPU3[count],'-*',label='GPU Kernel, block={0}'.
        \rightarrow format(nt), color=(0,1./(count+1),1))
           count+=1
       plt.ylabel('Time (sec)')
       plt.xlabel('N')
```

plt.xticks(dimension, dimension, rotation='vertical')

```
plt.legend(loc=2,labelspacing=0.5,fancybox=True, handlelength=1.5,⊔

→borderaxespad=0.25, borderpad=0.25)
```

[118]: <matplotlib.legend.Legend at 0x7fcbf8ef8a50>



le sfumature di blu corrispondono a un diverso numero di thread per blocco

[118]:

9 Numba

9.1 Numba è un metodo generico per utilizzare funzioni di C (tra cui roba di GPU) in python.

```
[2]: %reset
```

Once deleted, variables cannot be recovered. Proceed (y/[n])? y E' necessario far trovare due librerie che normalmente non sono nel path

```
[3]: import os os.environ['NUMBAPRO_LIBDEVICE'] = "/usr/local/cuda-10.0/nvvm/libdevice"
```

```
os.environ['NUMBAPRO_NVVM'] = "/usr/local/cuda-10.0/nvvm/lib64/libnvvm.so"
```

abbiamo già visto che numpy sfrutta il fatto che molte funzioni (ufunc, universal functions) sono compilate in C e aggiscono sugli elementi dei vettori in maniera automatia. Nel seguente esempio confrontiamo le performance di numpy con quelle della normale radice quadrata su opportuni vettori

```
[4]: import numpy as np
```

```
[5]: import math
x = np.arange(int(1e7), dtype=np.float32)
%timeit np.sqrt(x)
%timeit [math.sqrt(xx) for xx in x]
```

```
5.64 ms \pm 102 \mus per loop (mean \pm std. dev. of 7 runs, 100 loops each) 1.83 s \pm 137 ms per loop (mean \pm std. dev. of 7 runs, 1 loop each)
```

proviamo a compilare una funzione utente con numba. Per far questo usiamo il decoratore @vectorize

```
[6]: import math
import numpy as np
from numba import vectorize
@vectorize
def cpu_sqrt(x):
    return math.sqrt(x)
%timeit cpu_sqrt(x)
```

```
9.01 ms \pm 135 \mus per loop (mean \pm std. dev. of 7 runs, 1 loop each)
```

proviamo ora a fare una versione GPU in cui la ufunc è compilata per le essere eseguita sulla GPU. A differenza della funzione CPU è necessario specificare i tipi di output e input nel decoratore: output(input). L'array di input deve avere il tipo corretto.

```
[7]: @vectorize(['float32(float32)'], target='cuda')
def gpu_sqrt(x):
    return math.sqrt(x)
```

```
[8]: %timeit gpu_sqrt(x)
```


```
24.7 ms \pm 3.96 ms per loop (mean \pm std. dev. of 7 runs, 1 loop each)
```

apparentemente la versione GPU è piu' lenta della versione CPU. La ragione di questo è che l'operazione che stiamo facendo è troppo semplice e quindi non abbiamo vantaggio computazionale rispetto all'overhead di copiatura dell'array sul device.

facciamo un esempio piu' complicato. Generiamo dei punti in 2D con correlazione.


```
[10]: import matplotlib.pyplot as plt
plt.scatter(points[:,0], points[:,1])
```

[10]: <matplotlib.collections.PathCollection at 0x7fe0b7f4a2d0>



ora proviamo a trasformare in coordinate polari

```
[11]: theta = np.arctan2(points[:,1], points[:,0])
   _ = plt.hist(theta, bins=100)
```



vediamo 2 picchi perchè la correlazione puo' essere pi/4 o 3/4 pi. Proviamo a fare la stessa cosa con la GPU. Definiamo una ufunc gpu

return CUDAUFuncMechanism.call(self.functions, args, kws)

---> 36

```
37
        38
               def reduce(self, arg, stream=0):
       /usr/local/lib/python3.7/dist-packages/numba/np/ufunc/deviceufunc.py inu
→call(cls, typemap, args, kws)
       285
                           any_device = True
       286
                       else:
   --> 287
                           dev_a = cr.to_device(a, stream=stream)
       288
                           devarys.append(dev_a)
       289
       /usr/local/lib/python3.7/dist-packages/numba/cuda/vectorizers.py in u
→to_device(self, hostary, stream)
       168
       169
               def to_device(self, hostary, stream):
   --> 170
                   return cuda.to_device(hostary, stream=stream)
       171
       172
               def to_host(self, devary, stream):
       /usr/local/lib/python3.7/dist-packages/numba/cuda/cudadrv/devices.py in_
→_require_cuda_context(*args, **kws)
               def _require_cuda_context(*args, **kws):
       230
       231
                   with _runtime.ensure_context():
   --> 232
                       return fn(*args, **kws)
       233
       234
             return _require_cuda_context
       /usr/local/lib/python3.7/dist-packages/numba/cuda/api.py in_
→to_device(obj, stream, copy, to)
               if to is None:
       119
       120
                   to, new = devicearray.auto_device(obj, stream=stream,__

→copy=copy,

   --> 121
                                                     user_explicit=True)
       122
                   return to
       123
              if copy:
       /usr/local/lib/python3.7/dist-packages/numba/cuda/cudadrv/devicearray.py_
→in auto_device(obj, stream, copy, user_explicit)
       872
                           copy=False,
       873
                           subok=True)
   --> 874
                       sentry_contiguous(obj)
       875
                       devobj = from_array_like(obj, stream=stream)
```


```
876
                   if copy:
       /usr/local/lib/python3.7/dist-packages/numba/cuda/cudadrv/devicearray.py_
→in sentry_contiguous(ary)
       846
               core = array_core(ary)
               if not core.flags['C_CONTIGUOUS'] and not core.
       847
→flags['F_CONTIGUOUS']:
   --> 848
                   raise ValueError(errmsg_contiguous_buffer)
       849
       850
      ValueError: Array contains non-contiguous buffer and cannot be ⊔
→transferred as a single memory region. Please ensure contiguous buffer with
→numpy .ascontiguousarray()
```

il fatto è che stiamo scrivendo una funzione in C, che lavora con i puntatori. la y del primo punto è accanto alla x del primo punto. Quindi la prima colonna (delle x) contiene degli elementi a salti di uno


non funziona perchè le slice che abbiamo considerato non sono valori contigui in memoria, invece si devono passare array contigui come argomento. Per fortuna c'è una funzione per renderli contigui.

/usr/local/lib/python3.7/dist-packages/numba/cuda/dispatcher.py:488: NumbaPerformanceWarning: Grid size 1 will likely result in GPU under-utilization due to low occupancy.

warn(NumbaPerformanceWarning(msg))



funziona. Proviamo a farlo con piu' punti



quantifichiamo il tempo

```
[18]: %timeit np.arctan2(y, x)
```

299 ms \pm 5.28 ms per loop (mean \pm std. dev. of 7 runs, 1 loop each)

```
[19]: %timeit gpu_arctan2(y, x)
```

36 ms \pm 769 μ s per loop (mean \pm std. dev. of 7 runs, 10 loops each) visto che ci siamo confrontiamo anche con plain python


```
[20]: %timeit [math.atan2(point[1], point[0]) for point in points]
```


```
5.12 \text{ s} \pm 49.5 \text{ ms} per loop (mean \pm std. dev. of 7 runs, 1 loop each)
```

Nelle ufunc (su GPU o meno) che abbiamo visto fino ad ora, l'argomento è un array e il risultato è un array di scalari delle stesse dimensioni ottenuto applicando una funzione su ogni elemento dell'array di input. Vogliamo generalizzare questa cosa permettendo cosa piu' complicate, come il fatto che il calcolo avvenga solo su una parte dell'array di input e che l'output possa essere anche un array di dimensioni differenti da quello di input. Si usa guvectorize

```
x = vec[0]
y = vec[1]
out[0] = math.sqrt(x**2 + y**2)
out[1] = math.atan2(y,x)
```

```
[22]: polar_coords = gpu_polar(points)
```





facciamo un altro esempio su guvectorize, ovvero la media per righe in un vettore 2D

definiamo il vettore 2D

```
[26]: a = np.arange(100).reshape(20, 5).astype(np.float32)
a
```

```
[40., 41., 42., 43., 44.],

[45., 46., 47., 48., 49.],

[50., 51., 52., 53., 54.],

[55., 56., 57., 58., 59.],

[60., 61., 62., 63., 64.],

[65., 66., 67., 68., 69.],

[70., 71., 72., 73., 74.],

[75., 76., 77., 78., 79.],

[80., 81., 82., 83., 84.],

[85., 86., 87., 88., 89.],

[90., 91., 92., 93., 94.],

[95., 96., 97., 98., 99.]], dtype=float32)
```

[27]: gpu_average(a)

/usr/local/lib/python3.7/dist-packages/numba/cuda/dispatcher.py:488: NumbaPerformanceWarning: Grid size 1 will likely result in GPU under-utilization due to low occupancy.

warn(NumbaPerformanceWarning(msg))

```
[27]: array([ 2., 7., 12., 17., 22., 27., 32., 37., 42., 47., 52., 57., 62., 67., 72., 77., 82., 87., 92., 97.], dtype=float32)
```

10 Generare il PDF del Notebook

```
[]: |apt-get install texlive texlive-xetex texlive-latex-extra pandoc | pip install pypandoc
```

si deve montare il proprio google drive (seguire il link per ottenere la chiave di accesso)

```
[29]: from google.colab import drive drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force remount=True).

si deve copiare il notebook nella directory della macchina virtuale

```
[30]: cp "drive/My Drive/Colab Notebooks/handson_gpu_2022.ipynb" ./
```

ora si puo' convertire in pdf

```
[]: !jupyter nbconvert --to PDF "handson_gpu_2022.ipynb"
```

scaricare il file pdf prodotto dal menu files nel pannelo di sinistra (premere il destro sul file e fare download)

[]: !jupyter nbconvert --to LaTeX "handson_gpu_2022.ipynb"